

**THIAGO A. LIRA**  
**ADRIANO . DENNANNI**  
**RICARDO Y. NAGANO**

## **NETMAP**

Texto apresentado à Escola Politécnica da Universidade de São Paulo como requisito para a conclusão do curso de graduação em Engenharia de Computação, junto ao Departamento de Engenharia de Computação e Sistemas Digitais (PCS).

São Paulo  
2016

**THIAGO A. LIRA**  
**ADRIANO . DENNANNI**  
**RICARDO Y. NAGANO**

**NETMAP**

Texto apresentado à Escola Politécnica da Universidade de São Paulo como requisito para a conclusão do curso de graduação em Engenharia de Computação, junto ao Departamento de Engenharia de Computação e Sistemas Digitais (PCS).

Área de Concentração:

Engenharia de Computação

Orientador:

Reginaldo Arakaki

## FICHA CATALOGRÁFICA

Lira et al.

netmap/ T. A. Lira, A. . Dennanni, R. Y. Nagano. São Paulo, 2016.  
30 p.

Monografia (Graduação em Engenharia de Computação) — Escola Politécnica da Universidade de São Paulo. Departamento de Engenharia de Computação e Sistemas Digitais (PCS).

1. Assunto #1. 2. Assunto #2. 3. Assunto #3. I. Universidade de São Paulo. Escola Politécnica. Departamento de Engenharia de Computação e Sistemas Digitais (PCS). II. t.

## **AGRADECIMENTOS**

## **RESUMO**

Mapas físicos tornam-se cada vez menos utilizados com o desenvolvimento progressivo de sistemas de posicionamento cada vez melhores. O sistema americano GPS é possivelmente o mais utilizado, sendo que ele possibilita qualquer um ter informações sobre sua localização, dando apoio, por exemplo, à praticantes de trilhas e acampamentos, principalmente em casos de emergência. Porém, em ambientes fechados, as ondas eletromagnéticas utilizadas pelos satélites sofrem atenuações e interferências devidos aos materiais de construção, e assim o sistema perde precisão e não funciona com toda a precisão esperada. Como uma alternativa para esta dificuldade, procurou-se desenvolver um sistema, que consegue obter a posição do usuário em um ambiente fechado com precisão, sendo usado para isso técnicas de machine learning, aliadas com dados obtidos de redes em fio já instaladas no local. O sistema consistirá de um servidor central, onde serão enviados os dados e os mesmos serão processados. Os dados serão coletados por meio de um aplicativo de Android, este possuirá duas versões. A versão usuário usará os dados do servidor para localizar o usuário, a versão administrador irá coletar dados novos para serem usados em futuras medições. PALAVRAS-CHAVE: Indoor, Localização, Wi-fi, Machine Learning

## **ABSTRACT**

Physical maps are becoming each day less used due to constant evolution of positioning systems, better each day as well. The American system GPS probably is the most used and the most famous. It allows everyone to have their location information, giving support to hikers and campers, specially in emergency situations. On the other hand, in indoor environments, electromagnetic waves used by the satellites suffer with interference and mitigations and the systems loses precision and does not work as expected. As an alternative for this difficulty, it was developed a system that can locate the user position in an indoor environment with precision, using machine learning algorithms and data of wireless signals collected from the networks already existing on the place. The system consists on a main server that will receive the data and process it. The data will be collected with a Android app that will have two versions. The user version will use the server data to locate the user. The admin version will collect new data to be user on future measures. **KEY WORDS:** Indoor, Location, Wi-fi, Machine Learning

# SUMÁRIO

## Lista de Ilustrações

## Lista de Tabelas

<b>1</b>	<b>Introdução</b>	<b>9</b>
1.1	Apresentação . . . . .	9
1.2	Metodologia . . . . .	11
1.3	Fundamentação Teórica . . . . .	11
<b>2</b>	<b>Especificação</b>	<b>13</b>
2.1	Requisitos . . . . .	13
2.1.1	Requisitos Funcionais . . . . .	13
2.1.2	Requisitos Não-Funcionais . . . . .	13
2.2	Pontos de Vista . . . . .	14
2.2.1	Ponto de Vista da Empresa . . . . .	14
2.2.2	Ponto de Vista da Informação . . . . .	14
2.2.3	Ponto de Vista da Computação . . . . .	15
2.2.4	Ponto de Vista da Engenharia . . . . .	15
2.2.5	Ponto de Vista da Tecnologia . . . . .	16
<b>3</b>	<b>Machine Learning</b>	<b>17</b>



3.1	Tratamento dos dados . . . . .	17
3.1.1	Dados obtidos do Repositório UCI . . . . .	17
3.1.2	Dados do Servidor . . . . .	17
3.2	Formato dos dados tratados . . . . .	17
3.3	Modelos Usados e <i>Cross-Validation</i> de parâmetros . . . . .	18
3.3.1	KNN : K-Nearest-Neighbors . . . . .	19
3.3.2	Rede Neural . . . . .	20
3.3.3	Arvore de decisão . . . . .	21
3.3.3.1	Acoplamento com o Algoritmo AdaBoost . . . . .	22
3.3.4	Comparação dos Modelos Usados . . . . .	23
3.4	Métodos de Votação . . . . .	28
3.4.1	Testes com os Métodos de Votação . . . . .	28

<b>Referências</b>	<b>30</b>
--------------------	-----------

## LISTA DE ILUSTRAÇÕES

1	Erros para uso de Diferentes Distâncias . . . . .	19
2	Erro em função do número de vizinhos . . . . .	20
3	Erro para diversas quantidades de neurônios na rede neural. . . . .	21
4	Teste de Validação do Algoritmo C4.5 . . . . .	22
5	Comparação do C4.5 com o uso do AdaBoost . . . . .	23
6	Erro do algoritmo SMO para uma quantidade crescente de zonas de classificação. . . . .	24
7	Erro do algoritmo de Redes Neurais para uma quantidade crescente de zonas de classificação. . . . .	25
8	Erro do algoritmo KNN para uma quantidade crescente de zonas de classificação. . . . .	26
9	Erro do algoritmo de Árvore de Decisão com e sem o Adaboost para uma quantidade crescente de zonas de classificação. . . . .	27
10	Erro do Voto Simples e Voto Ponderado para uma quantidade crescente de zonas de classificação. . . . .	29

## **LISTA DE TABELAS**

# 1 INTRODUÇÃO

## 1.1 Apresentação

Com a modernização das tecnologias de telefonia móvel torna-se cada vez maior o número de pessoas com celulares associados a tecnologias de rede, como WiFi, 3G e 4G, que tem o potencial de fornecer informações sobre seu usuário a todo momento, tais como o conteúdo acessado por seus navegadores ou aplicativos, e também informações sobre posição e deslocamento. Dados de localização por si possuem pouco valor, mas quando aliados a outros conteúdos, é possível fornecer conteúdo personalizado em tempo real, reativo ao ambiente, passando a oferecer um grande retorno por um pouco mais de ocupação na banda.

Enquanto sistemas de posicionamento por satélite como GPS (EUA) ou GALILEO (Europa), por um lado, conseguem precisar a posição do usuário em até centímetros em um ambiente outdoor, por outro há uma dificuldade deste sistema em calcular o posicionamento em lugares fechados, devido basicamente à atenuação dos sinais causada pelas paredes e seus materiais. Tendo em vista o crescimento das cidades e consequente aumento no número de construções as pessoas cada vez passam mais tempo em ambientes fechados. A necessidade de serviços de localização indoor tem se tornado cada vez mais crítica.

Respondendo a essa necessidade surgiram alternativas para o posicionamento em ambientes fechado, entre eles há o uso da Identificação por Rádio Frequência (RFID - Radio Frequency IDentification), do bluetooth, do Zigbee ou do Wi-fi. A determinação

de posicionamento via Wi-fi é uma tecnologia que usa os sinais modulados do Wi-fi para; detectar a presença de um aparelho, em seguida o sistema é capaz de triangular a posição deste aparelho a partir dos sinais recebidos pelo ponto de acesso. Um dos primeiros exemplos de um sistema de posicionamento utilizando Wi-fi foi RADAR, desenvolvido pela Microsoft, que também criou o RightSPOT que utilizava um ranking das frequências moduladas pelos pontos de acesso, no lugar de usar a potência dos sinais para determinar a posição do aparelho.

Tendo em vista este cenário e as condições tecnológicas atuais, nosso projeto procura apresentar uma solução para localização de pessoas em ambientes fechados, como shoppings e eventos em galpões. Para tal, será combinado o uso de Big Data à tecnologia de Wi-fi já citada e ainda implementando um algoritmo de machine learning. O Big Data, que possui como uma de suas principais características a capacidade de armazenar uma grande quantidade de dados, será usado para armazenar todas as leituras de intensidade dos sinais feitas durante uma fase inicial, chamada de treinamento. À partir dessa larga quantidade de dados recebidos serão empregados algoritmos de machine learning processando-os para permitir que o sistema consiga determinar a posição do usuário dentro do ambiente mapeado anteriormente.

Esta abordagem se mostra interessante ao ponto de que sua implementação não necessita configuração particular na rede que será usada, uma vez que se baseia em leituras feitas pelo aparelho móvel e no processamento dos dados feitos em um servidor em nuvem. Também se destaca o fato de que em decorrência do machine learning à medida de que o sistema é usado em uma determinada localidade a precisão tende a aumentar, uma vez que cada vez há mais dados para serem consultados para "Aprendizado". Esse approach difere de outro também amplamente empregado em esquemas de localização indoor, que é o de modelar o próprio sinal de Wi-Fi, deduzindo a sua distância a partir da intensidade medida. Esse método se torna ineficiente porque se torna necessário que sejam conhecidas as coordenadas de todas as APs locais, e tam-

bém o próprio modelo de atenuação dos sinais RSSI de WiFi sofrem todo o tipo de interferência tornando difícil a obtenção de uma boa precisão.

## 1.2 Metodologia

O projeto pode ser dividido em dois módulos principais: aquisição de dados e localização. O módulo de aquisição será desenvolvido com a ajuda de testes em Shopping Centers de São Paulo, colhendo dados das redes wireless através de um aplicativo Android feito especialmente por isso, durante todo o desenvolvimento do projeto. Esses dados serão úteis para calibrar o sistema de Machine Learning que será desenvolvido em paralelo na linguagem estatística R. Os dados são enviados do aplicativo Android para o sistema de Machine Learning através de uma API construída na linguagem Ruby. O módulo de localização consistirá num aplicativo Android que confirmará as posições colhidas anteriormente no módulo de aquisição de dados, usando para isso os resultados obtidos com o Machine Learning.

## 1.3 Fundamentação Teórica

A teoria de Machine Learning está sendo baseada no curso "Machine Learning" do Coursera, ministrado por Andrew Ng (Professor associado da Faculdade de Stanford). Técnicas de tratamento de dados estão sendo aprendidas no curso (Também do Coursera) "Getting and Cleaning Data", ministrado por diversos professores da Universidade John Hopkins. Os fundamentos de Machine Learning se baseiam primeiramente em álgebra linear, no tratamento de matrizes de dados, sendo necessário diversas multiplicações de matrizes com dimensões de mais de 1000 linhas e colunas.

Em segundo lugar, temos algoritmos de otimização de funções de custo, esses usando os gradientes numéricos dessas funções para que se ache um mínimo global ou local delas em função dos parâmetros que desejamos minimizar com a técnica de Ma-

chine Learning. Com base no curso do Coursera, já foram implementados algoritmos de machine learning capazes de detectar "spam" em uma caixa de e-mails (Usando redes neurais) e um algoritmo de reconhecimento de dígitos manuscritos, esse implementado tanto em redes neurais como regressão logística (com diversas classes). Também foi feito um exercício de tratamento de dados usando o popular aplicativo de mensagens Whatsapp, onde foram usados backups de mensagens para criar estatísticas de usuários, como por exemplo, a palavra que eles mais falam ou a quantidade de vezes que tal palavra foi escrita. Todos esses exercícios foram implementados em R e Matlab.

## **2 ESPECIFICAÇÃO**

### **2.1 Requisitos**

#### **2.1.1 Requisitos Funcionais**

- Enviar dados sobre a intensidade dos sinais de Wi-Fi ao servidor.
- Retornar a posição do usuário baseado nos dados enviados.
- Disponibilizar uma API para ser usada por outros aplicativos.
- Implementar machine learning com redes neurais para o sistema "aprender" as posições do ambiente.

#### **2.1.2 Requisitos Não-Funcionais**

- A margem de erro para a posição do usuário deve ser de 10%.
- O sistema deve ser transparente ao usuário.
- O MTBF deve ser de 10000 horas.
- O tempo de resposta para a aquisição dos dados dos sinais deve ser da ordem de milissegundos.
- O tempo de resposta do serviço para definição da posição deve ser da ordem de milissegundos.
- Consumo de bateria médio de 200 mAh por hora.



- MTTR do sistema deve ser no máximo de 8h.
- No futuro deve ser empregada uma redundância nos servidores para otimizar a disponibilidade e segurança do sistema.

## **2.2 Pontos de Vista**

### **2.2.1 Ponto de Vista da Empresa**

Este projeto deverá criar um sistema de localização precisa em ambientes fechados, utilizando como parâmetros as intensidades de sinais redes sem fio próximas. O resultado deste projeto incluirá duas aplicações:

Aplicativo para o celular com dois módulos utilizados para capturar informações das redes sem fio próximas e enviá-las servidor, além de receber resultados deste servidor e exibi-los para o usuário;

Aplicação em nuvem que receberá os dados dos celulares e responderá com a localização do usuário.

Para tal serão feitas análises estatísticas do comportamento e flutuação do sinal de Wi-Fi em diversas medições e com aparelhos de celular diferentes e posteriormente, estes dados serão analisados por um algoritmo de inteligência artificial baseado em machine learning, para que a localização seja definida.

### **2.2.2 Ponto de Vista da Informação**

As informações processadas pelo sistema seguirão dois fluxos. No primeiro as intensidades dos sinais provenientes dos pontos de acesso de redes sem fio serão capturadas pelo sensor do celular e registradas pelo módulo de aquisição de dados do aplicativo. Em seguida, estas informações serão enviadas para o servidor para que recebam o devido tratamento.

Após o período de treinamento do sistema o segundo fluxo será possível. Nele após o dispositivo móvel enviar os sinais capturados por um usuário regular, o servidor deve executar seu algoritmo de machine learning e retornar à posição que o usuário se encontra dentro do prédio previamente estabelecido, usando como base estes dados enviados.

A troca de dados em ambos os fluxos será feita usando o formato JSON, este formato é muito utilizado principalmente quando é necessária a implementação de tabelas de bancos de dados por conta de sua simplicidade para manipular as informações representadas.

### **2.2.3 Ponto de Vista da Computação**

O sistema será composto por duas partes funcionais, a primeira é o aplicativo desenvolvido para dispositivos Android, ele será responsável pela captura dos dados, em seguida ele organizará as informações coletas no formato JSON e finalmente realizará a transmissão por meio da rede à qual o dispositivo estiver conectado, uma rede 3G/4G ou pela conexão a uma rede Wi-Fi disponível.

A segunda parte é o servidor em nuvem, que deverá processar os dados executando o algoritmo de machine learning e em seguida disponibilizará os resultados obtidos para posterior consulta feita quando forem requisitadas informações a respeito do ambiente fechado já mapeado anteriormente, retornando a posição do usuário.

### **2.2.4 Ponto de Vista da Engenharia**

Para o uso do sistema será necessário que o dispositivo móvel que executar o aplicativo tenha uma antena de WiFi, para que possam ser realizadas as medições de intensidades dos sinais. Tais dados serão enviados pela própria antena de WiFi usando a rede que estiver conectada ou pela antena de 3G/4G usando as redes móveis para o servidor. O serviço funcionará em uma máquina virtual hospedada no serviço Heroku,

esta máquina deverá suportar uma grande quantidade de dados, além de ter um poder de processamento capaz de suportar a execução do algoritmo de machine learning.

É necessário também que exista uma estrutura mínima no local a ser mapeado, deve existir um número mínimo de pontos de acesso de rede sem fio suficiente para englobar todo o ambiente. Esta cobertura não deve ser apenas de pelo menos um sinal Wi-Fi na parcela de área, é indispensável que mais de um sinal atinja cada ponto para que seja possível haver a determinação do ponto escolhido.

### **2.2.5 Ponto de Vista da Tecnologia**

O processamento e aplicação dos algoritmos de machine learning serão feitos por meio da linguagem R. O aplicativo é feito para a plataforma Android e o servidor é implementado na plataforma Ruby on Rails, hospedado em um serviço chamado Heroku, para pequenas aplicações que devem rodar na nuvem.

## 3 MACHINE LEARNING

### 3.1 Tratamento dos dados

#### 3.1.1 Dados obtidos do Repositório UCI

Para grande parte dos testes de *Cross-Validation*, foi usado *dataset* UJIIndoorLoc apresentado em (TORRES-SOSPEDRA et al., 2014). O *dataset* consiste em diversas medidas de potência de sinal Wi-Fi medidas com diversos aparelhos celulares em 3 prédios diferentes de uma faculdade. As medidas estão separadas por prédio, andar e sala. Para os fins dessa monografia, serão realizados testes com medidas sempre de um mesmo andar, afim de classificar as zonas de um mesmo ambiente.

#### 3.1.2 Dados do Servidor

### 3.2 Formato dos dados tratados

A matriz de dados tratados usada diretamente pelos algoritmos de ML tem o seguinte formato:

$$\begin{array}{ccccc}
 \text{ZoneID} & BSSID_1 & BSSID_2 & \dots & BSSID_n \\
 \left( \begin{array}{ccccc}
 1 & -70 & -92 & \dots & -87 \\
 2 & -89 & -80 & \dots & -63 \\
 3 & -28 & -120 & \dots & -35 \\
 \vdots & \vdots & \vdots & \ddots & \vdots \\
 1 & -48 & -36 & \dots & -29
 \end{array} \right) & \begin{array}{l}
 Measure_1 \\
 Measure_2 \\
 Measure_3 \\
 \vdots \\
 Measure_n
 \end{array}
 \end{array}$$

Cada coluna representa a medida de uma *BSSID* (i.e. um Roteador), ou seja, uma *feature* para o ML, e cada linha é um ponto de treino (i.e. uma medida para cada *BSSID*, nossas *features*).


### 3.3 Modelos Usados e *Cross-Validation* de parâmetros

A chamada *Cross-Validation* dos modelos de ML é o teste para encontrar os parâmetros ótimos para o treinamento. Um dos métodos escolhidos de *Cross-Validation* foi o *K-Fold*. O método *K-Fold* divide o dataset em  $K$  subconjuntos de igual tamanho e então um dos conjuntos é usado como validação do treinamento feito pelos  $K - 1$  subconjuntos restantes. O processo é repetido  $K$  vezes e em cada subdivisão possível podem ser usados valores de parâmetros de treino distintos. Para a comparação dos modelos, serão feitos diversos testes com um número crescente de zonas de classificação. Nesse caso, são escolhidas iterativamente e aleatoriamente  $n$  zonas do **dataset** UJIIndoorLoc, são pegos todos os pontos associados as  $n$  zonas seleccionadas. Então, o **dataset** é separado em 80% de pontos de treino e 20% para testes. Para valores de  $n$  de 1 a 30 são finalmente medidos as taxas de erro de cada algoritmo e essa informação é apresentada em gráficos.

### 3.3.1 KNN : K-Nearest-Neighbors

Para o algoritmo de KNN, foram feitos dois testes de *Cross-Validation*. No primeiro, a métrica de distância foi decidida, e no segundo, o número de vizinhos ( $K$ ). Para que fosse definida a métrica de distância, foi usado o método *K-Fold* com  $K = 2$ . E em cada *fold* o modelo foi treinado com uma métrica diferente. Foram calculados 20 conjuntos diferentes de *folds* e foi tirada a média do erro de validação para cada uma das métricas.


Figura 1: Erros para uso de Diferentes Distâncias



Depois, foi usado o método *K-Fold* com  $K = 10$  para a decisão do número de vizinhos. Foram testados os valores de 1 até 10 para o número de vizinhos. Na imagem a seguir vemos detalhes desse teste.

Podemos concluir então que (1) o erro é menor no geral com a distância de Manhattan e (2) embora tenha muita variância envolvida no teste, o valor de  $K$  que mini-

Figura 2: Erro em função do número de vizinhos



miza o erro fica próximo de 4 vizinhos.


No restante do trabalho foi escolhido o valor de  $K = 4$  vizinhos.

### 3.3.2 Rede Neural

Para a *Cross-Validation* das Redes Neurais, também foi usado o método de *K-Fold* com  $K = 10$ . Para cada uns dos *folds* foi testado um número de neurônios em uma *hidden-layer* única. (Outros testes mostraram não valer a pena para o nosso problema usar mais de uma camada de *hidden layer* ou *deep learning*). Os resultados são mostrados a seguir:

Concluimos que o número ideal de neurônios na *hidden-layer* está próximo de 200. E é esse valor que usaremos daqui para frente.

Figura 3: Erro para diversas quantidades de neurônios na rede neural.




### 3.3.3 Arvore de decisão

Baseado no trabalho apresentado por (BOZKURT et al., 2015), foi escolhida uma implementação do algoritmo C4.5 (QUINLAN, 1993) em Java, da biblioteca Weka, para serem geradas árvores de decisão. Os métodos porém foram chamados pela interface da Weka para R, chamada RWeka. A função J48 do Weka foi testada com os pontos de treino referentes ao primeiro andar do prédio 1 (i.e. BuildingID 1, FloorID 0) do dataset UJIIndoorLoc. Foi levantada a curva de erro de classificação para uma quantidade crescente de pontos de treino (como explicado em 2.3).



Figura 4: Teste de Validação do Algoritmo C4.5




### 3.3.3.1 Acoplamento com o Algoritmo AdaBoost

*Boosting* é a ideia em ML de criar uma predição forte e precisa combinando diversas previsões mais fracas. O algoritmo AdaBoost (FREUND; SCHAPIRE, 1996) é um método para melhorar a precisão de classificadores fracos (i.e. *Weak Learners*) por meio de uma votação ponderada que leva em conta o erro de diversos votadores fracos treinados no processo. É provado que o modelo final se torna um classificador forte (SCHAPIRE, ). Por definição, um classificador fraco é aquele que consistentemente consegue ser melhor que um chute para a classificação (e.g. o erro é menor que 50% para o caso de duas classes possíveis de classificação).

Também baseados em (BOZKURT et al., 2015) e (MACLIN; OPITZ, 2011). Usaremos o algoritmo AdaBoost e sua implementação na biblioteca Weka para melhorar a

precisão das árvores de decisão C4.5. A seguir vemos um gráfico comparando a classificação para o mesmo andar do dataset UJIIndoorLoc com os mesmos pontos de teste e uma quantidade crescente de pontos de treino, assim como feito no tópico anterior.

Figura 5: Comparação do C4.5 com o uso do AdaBoost



Podemos notar que com um número grande de pontos de treino, obtemos uma melhora sensível de precisão para a classificação, e portanto, no restante do trabalho, iremos usar o algoritmo C4.5 acoplado com o algoritmo AdaBoost.

### 3.3.4 Comparação dos Modelos Usados

Reiterando o que foi explicado em outra sessão, os testes a seguir irão contemplar todos os modelos usados. Os modelos tem seu erro testado para datasets com um número crescente de zonas aleatórias a serem classificadas. Todos os testes foram feitos com os dados do primeiro andar do prédio 1 do dataset UJIIndoorLoc (i.e. BuildingID 1, FloorID 0).

Figura 6: Erro do algoritmo SMO para uma quantidade crescente de zonas de classificação.




Figura 7: Erro do algoritmo de Redes Neurais para uma quantidade crescente de zonas de classificação.




Figura 8: Erro do algoritmo KNN para uma quantidade crescente de zonas de classificação.





Figura 9: Erro do algoritmo de Árvore de Decisão com e sem o Adaboost para uma quantidade crescente de zonas de classificação.




## 3.4 Métodos de Votação

Os chamados sistemas de *Ensemble Learning* são aqueles em que uma classificação é feita com base em diversos modelos treinados. Em tópicos anteriores foi discutido o uso do algoritmo AdaBoost, que é um método desse tipo para melhorar o poder de classificadores fracos treinando iterativamente diversos modelos fracos progressivamente com os erros do anterior (SCHAPIRE, ). Porém, para agregar os modelos usados até agora, iremos implementar algo mais simples, porém seguindo a mesma lógica: Sistemas de Votação. Baseados em (NAGI; BHATTACHARYYA, 2013), usaremos diversos métodos para combinar as classificações dos nossos modelos treinados. Em um, usaremos apenas a classe de saída dos modelos, e posteriormente, as probabilidades (*supports*) para cada uma das classes, que também são saídas dos modelos. Esses *supports* podem ser, dependendo do modelo, a probabilidade posterior ou o grau de confiança fornecido pelos algoritmos. Por exemplo, nas redes neurais a saída de um neurônio é a função sigmoide aplicada nas entradas multiplicada pela matriz de pesos da rede, que, por definição, é um número entre 0 e 1 que representa uma probabilidade.

### 3.4.1 Testes com os Métodos de Votação

Como na sessão de comparação dos modelos, os métodos tem seu erro testado para datasets com um número crescente de zonas aleatórias a serem classificadas. Todos os testes foram feitos com os dados do primeiro andar do prédio 1 do dataset UJIIndoor-Loc (i.e. BuildingID 1, FloorID 0).

Figura 10: Erro do Voto Simples e Voto Ponderado para uma quantidade crescente de zonas de classificação.





## REFERÊNCIAS

- BOZKURT, S.; ELIBOL, G.; GUNAL, S.; YAYAN, U. A comparative study on machine learning algorithms for indoor positioning. In: *Innovations in Intelligent SysTems and Applications (INISTA), 2015 International Symposium on*. [S.l.: s.n.], 2015. p. 1–8.
- FREUND, Y.; SCHAPIRE, R. E. *A Decision-Theoretic Generalization of on-Line Learning and an Application to Boosting*. 1996.
- MACLIN, R.; OPITZ, D. W. Popular ensemble methods: An empirical study. *CoRR*, abs/1106.0257, 2011. Disponível em: <<http://arxiv.org/abs/1106.0257>>. Acesso em: 29 de outubro de 2016.
- NAGI, S.; BHATTACHARYYA, D. K. Classification of microarray cancer data using ensemble approach. *Network Modeling Analysis in Health Informatics and Bioinformatics*, v. 2, n. 3, p. 159–173, 2013. ISSN 2192-6670. Disponível em: <<http://dx.doi.org/10.1007/s13721-013-0034-x>>. Acesso em: 29 de outubro de 2016.
- QUINLAN, R. *C4.5: Programs for Machine Learning*. San Mateo, CA: Morgan Kaufmann Publishers, 1993.
- SCHAPIRE, R. E. *Explaining AdaBoost*.
- TORRES-SOSPEDRA, J.; MONTOLIU, R.; MARTÍNEZ-USÓ, A.; AVARIENTO, J. P.; ARNAU, T. J.; BENEDITO-BORDONAU, M.; HUERTA, J. Ujiindoorloc: A new multi-building and multi-floor database for wlan fingerprint-based indoor localization problems. In: *Indoor Positioning and Indoor Navigation (IPIN), 2014 International Conference on*. [S.l.: s.n.], 2014. p. 261–270.